

第四章 矩阵特征值与特征向量的计算

第四章 矩阵特征值与特征向量的计算

- 引言
- 幂法
- 反幂法

4.1 引言

定义 设 A 是 n 阶矩阵, 如果存在数 λ 和 n 维非零向量 α , 使

$$A\alpha = \lambda\alpha$$

则称 λ 为方阵 A 的一个特征值, α 为方阵 A 对应于特征值 λ 的一个特征向量.

1° A 的特征值 λ 由它的特征方程 $\varphi(\lambda) = \det(\lambda I - A) = 0$ 的根确定.

2° 设 λ 为 A 的特征值, 求齐次线性方程组 $(\lambda I - A)x = 0$ 的非零解, 便得到 A 的属于 λ 的特征向量.

设 $A\alpha = \lambda\alpha$ ($\alpha \neq 0$), 则 $(\lambda I - A)\alpha = 0$.

α 是 $(\lambda I - A)X = 0$ 的非零解.

求 A 的特征值与特征向量的步骤如下:

(1) 求 $|\lambda I - A| = 0$ 的根: $\lambda_1, \lambda_2, \dots, \lambda_k$;

(2) 求 $(\lambda_i I - A)X = 0$ 的基础解系:

$$\alpha_{i_1}, \alpha_{i_2}, \dots, \alpha_{i_{r_i}},$$

则 A 对应于 λ_i 的特征向量为:

$$k_1 \alpha_{i_1} + k_2 \alpha_{i_2} + \dots + k_{r_i} \alpha_{i_{r_i}} \quad (k_1, k_2, \dots, k_{r_i} \text{ 不全为零}).$$

回顾几个基本结论:

定理1 若 $\lambda_i(i=1,2,\dots,n)$ 为 A 的特征值, 则有

$$(1) \quad \sum_{i=1}^n \lambda_i = \sum_{i=1}^n \alpha_{ii} = \text{tr}(A)$$

$$(2) \quad \det(A) = \lambda_1 \lambda_2 \dots \lambda_n$$

定理2 设 A 与 B 为相似矩阵, 即存在可逆矩阵 P , 使得 $P^{-1}AP=B$, 则

(1) A 与 B 有相同的特征值;

(2) 若 x 为 B 的一个特征向量, 则 Px 为 A 的特征向量.

定理3 (Gerschgorin's定理) 设 $A=(a_{ij})_{n \times n}$, 则 A 的每一个特征值, 必属于下述某个圆盘之中:

$$|\lambda - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, \quad (i = 1, \dots, n)$$

且如果一个特征向量的第 i 个分量绝对值最大, 则对应的特征值一定属于第 i 个圆盘中.

例1 估计方阵特征值的范围

$$A = \begin{bmatrix} 1 & 0.1 & 0.2 & 0.3 \\ 0.5 & 3 & 0.1 & 0.2 \\ 1 & 0.3 & -1 & 0.5 \\ 0.2 & -0.3 & -0.1 & -4 \end{bmatrix}$$


解：

$$G_1 = \{z: |z - 1| \leq 0.6\};$$

$$G_2 = \{z: |z - 3| \leq 0.8\};$$

$$G_3 = \{z: |z + 1| \leq 1.8\};$$

$$G_4 = \{z: |z + 4| \leq 0.6\}.$$



注：定理称 A 的 n 个特征值全落在 n 个盖氏圆上，但未说明每个圆盘内都有一个特征值。

4.2 幂法

用于求矩阵的按模最大的特征值与相应的特征向量的近似值.

设 A 为 n 阶实矩阵,

λ_i, u_i ($i = 1, 2, \dots, n$)为 A 的特征值和相应的特征向量,

且满足: $|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$

u_1, u_2, \dots, u_n , 线性无关.

幂法: 求 λ_1 及其对应的特征向量.

λ_1 通常称为主特征值.

幂法基本思想:

给定初始非零向量 $x^{(0)}$, 由矩阵 A 构造一向量序列

$$\begin{cases} x^{(1)} = Ax^{(0)} \\ x^{(2)} = Ax^{(1)} = A^2 x^{(0)} \\ \dots \\ x^{(k+1)} = Ax^{(k)} = A^{k+1} x^{(0)} \\ \dots \end{cases}$$

在一定条件下, 当 k 充分大时: $\lambda_1 \approx \frac{x_i^{(k+1)}}{x_i^{(k)}}$

相应的特征向量为: $x^{(k+1)}$

幂法的理论依据:

对任意向量 $x^{(0)}$, 有 $x^{(0)} = \sum_{i=1}^n t_i u_i$, 设 t_1 不为零.

$$x^{(k+1)} = Ax^{(k)} = A^{k+1}x^{(0)}$$

$$= \sum_{i=1}^n A^{k+1} t_i u_i = \sum_{i=1}^n t_i \lambda_i^{k+1} u_i$$

$$= \lambda_1^{k+1} \left[t_1 u_1 + \left(\frac{\lambda_2}{\lambda_1} \right)^{k+1} t_2 u_2 + \cdots + \left(\frac{\lambda_n}{\lambda_1} \right)^{k+1} t_n u_n \right]$$

$$\approx \lambda_1^{k+1} t_1 u_1$$

故 $\lambda_1 \approx x_i^{(k+1)} / x_i^{(k)}$

$x^{(k+1)}$ 为 λ_1 的特征向量的近似向量(除一个因子外).

● 如果 $x^{(0)}$ 的选取恰恰使得 $t_1=0$, 幂法仍能进行. 因为计算过程中会有舍入误差, 迭代若干次后, 必然会产生一个向量 $x^{(k)}$, 它在 u_1 方向上的分量不为零, 这样以后的计算就满足所设条件.

● 因为 $x^{(k)} \approx \lambda_1^k t_1 u_1$, 计算过程中可能会出现上溢 ($|\lambda_1| > 1$) 或下溢成为 0 ($|\lambda_1| < 1$). 为避免出现这一情形, 实际计算时每次迭代所求的向量都要归一化.

归一化过程:

设有一向量 $x \neq 0$, 将其归一化得到向量

$$y = \frac{x}{\max(x)}$$

其中 $\max(x)$ 表示向量 x 的绝对值最大的分量, 即如果有

$$|x_{i_0}| = \max_{1 \leq i \leq n} |x_i|$$

则 $\max(x) = x_{i_0}$, 且 i_0 为所有绝对值最大的分量中的最小下标.

例 $x = (1, -8, 7)^T$, 则 $\max(x) = -8$, 归一化向量为

$$y = \frac{x}{\max(x)} = (-0.125, 1, -0.875)^T$$

幂法的计算公式:

任取初始向量 $x^{(0)}=y^{(0)}\neq 0$, 对 $k=1, 2, \dots$, 构造向量序列 $\{x^{(k)}\}, \{y^{(k)}\}$

$$\begin{cases} x^{(k)} = Ay^{(k-1)} \\ \alpha_k = \max(x^{(k)}) \\ y^{(k)} = \frac{x^{(k)}}{\alpha_k} \end{cases}$$

当 k 充分大时, $\alpha_k \approx \lambda_1, y^{(k)} \approx \frac{u_1}{\max(u_1)}$